

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Momento de Retroalimentación: Módulo 2 Análisis y Reporte sobre el desempeño del modelo. (Portafolio Análisis)

Jorge Adolfo Ramírez Uresti

Israel González Huerta A01751433

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Lunes 21 de septiembre de 2026

Introducción

Elegí trabajar con la implementación de random forest que realicé con un framework.

En las siguientes secciones detallaré el porqué el modelo llegó a la versión final, explicando como los parámetros e hiperparámetros afectaron el grado de bias, varianza y nivel de ajuste. Este reporte mostrará de manera iterativa los cambios realizados para cada modelos y sus resultados. Cada iteración inicia con 3 secciones hablando de cómo el grado de bias, varianza y nivel de ajuste fueron afectados tras hacer los cambios correspondiente al modelo, los datos y gráficos que informaron los cambios al modelo y los resultados de estos cambios están en la sección de Resultados de cada iteración.

Separación y evaluación de los datos

Se utilizó el dataset de Titanic (obtenido de <https://www.kaggle.com/datasets/yasserh/titanic-dataset?select=Titanic-Dataset.csv>).

Los datos fueron separados en un 60/20/20 para datos de entrenamiento, prueba y validación. Inicialmente los datos fueron separados de manera aleatoria y no se tomó consideración para estratificar o modificar el conjunto de datos de alguna otra manera.

Modelo original

Diagnóstico y explicación el grado de bias o sesgo

El bias se considera bajo.

El modelo obtiene un accuracy de 98.31% en el conjunto de entrenamiento y mantiene un desempeño de aproximadamente 81-82% en los conjuntos que no utilizó para entrenar. Esto indica que el modelo tiene una buena capacidad para aprender los patrones presentes en los datos de entrenamiento.

Sin embargo, el accuracy de los conjuntos de validación y prueba es considerablemente menor que el de entrenamiento, por lo que concluyo que el problema principal del modelo no es un bias alto.

Diagnóstico y explicación el grado de varianza

La varianza se considera alta.

El modelo alcanza un accuracy de 98.31% en entrenamiento, mientras que obtiene 82.02% en validación y 81.01% en prueba. Esto representa una diferencia de 16.29 puntos porcentuales entre Train y Validation y de 17.31 puntos porcentuales entre Train y Test. Esta diferencia indica que el modelo tiene un desempeño considerablemente mejor sobre los datos con los que fue entrenado que sobre datos que no había visto, lo cual es indicativo de una varianza alta.

Diagnóstico y explicación el nivel de ajuste del modelo

El modelo presenta overfitting.

El accuracy de entrenamiento de 98.31% es muy superior al accuracy de validación de 82.02% y al accuracy de prueba de 81.01%. Esto indica que el Random Forest está aprendiendo los datos de entrenamiento con mucha precisión, pero su desempeño disminuye considerablemente al enfrentarse a datos nuevos.

Los resultados de validación y prueba son relativamente cercanos entre sí, lo que indica que la disminución de desempeño no se debe a una diferencia importante entre estos dos conjuntos, sino principalmente a la gran diferencia respecto al conjunto de entrenamiento.

El comportamiento observado es consistente con un modelo que presenta overfitting y una varianza alta.

Resultados

- Definí las condiciones iniciales a partir de mi análisis de la implementación con framework, estos resultados son los que se pretende superar modificando el modelo:

NUMERO_ARBOLES = 100

PROFUNDIDAD_MAXIMA = None

MINIMO_MUESTRAS_DIVISION = 2

MINIMO_MUESTRAS_HOJA = 1

NUMERO_MAXIMO_CARACTERISTICAS = "sqrt"

SEMILLA = 42

```
=====
SEPARACIÓN DE LOS DATOS
=====
Datos de entrenamiento: 534
Datos de validación:    178
Datos de prueba:        179

=====
ACCURACY DEL MODELO
=====
Accuracy de entrenamiento: 98.31%
Accuracy de validación:    82.02%
Accuracy de prueba:        81.01%

=====
Diferencias de accuracy
=====
Diferencia Train-Validation: 16.29%
Diferencia Train-Test:      17.31%
```

```
=====
REPORTE DE CLASIFICACIÓN - VALIDACIÓN
=====
              precision    recall  f1-score   support


     0       0.86       0.86       0.86       112
     1       0.76       0.76       0.76        66

 accuracy          0.82       178
  macro avg       0.81       0.81       0.81       178
 weighted avg     0.82       0.82       0.82       178

=====
REPORTE DE CLASIFICACIÓN - PRUEBA
=====
              precision    recall  f1-score   support

     0       0.83       0.85       0.84       105
     1       0.78       0.76       0.77        74

 accuracy          0.81       179
  macro avg       0.80       0.80       0.80       179
 weighted avg     0.81       0.81       0.81       179
```



Iteración 1 (profundidad del árbol)

Diagnóstico y explicación el grado de bias o sesgo

Las gráficas de “Desempeño del Random Forest según max_depth” ilustra como conforme aumenta con el max_depth el accuracy para los datos de entrenamiento crece mientras que el accuracy para los datos de validación tiende a disminuir. Esta conducta indica overfitting. Por su parte, el accuracy para los datos de prueba tiende a ser mayor para valores más altos de max_depth, pero usualmente el valor más alto se encuentra entre una profundidad de 9 y 11.

Decidí probar el modelo con una profundidad de árbol de 10.

Diagnóstico y explicación el grado de varianza

La diferencia crece entre mayor es el max_depth, esto es indicativo de un overfitting. Vale la pena recalcar que la diferencia entre el accuracy de validation y test es muy pequeña, mostrando poca diferencia con datos parcial o totalmente desconocidos, pero que ha “memorizado” los de entrenamiento.

Diagnóstico y explicación el nivel de ajuste del modelo



Comparando con el modelo original el accuracy de entrenamiento ha disminuido (pero sigue siendo mayor que el de validación), el accuracy de validación aumentó (marginalmente) y el accuracy de prueba se mantuvo prácticamente igual.

Todos los resultados siguen siendo indicativos de un overfit, pero tras este cambio ha disminuido la varianza.



Resultados

Gráficas de los resultados del accuracy dependiendo de la profundidad máxima del árbol. Estas dos gráficas son resultados de correr exactamente el mismo modelo 2 veces (sin una random seed) para ilustrar el comportamiento general.

Gráficas para determinar el sesgo.



Gráficas para determinar la varianza.



Resultados de correr el modelo con un max Depth de 10

SEPARACIÓN DE LOS DATOS

Datos de entrenamiento: 534
 Datos de validación: 178
 Datos de prueba: 179

ACCURACY DEL MODELO

Accuracy de entrenamiento: 94.94%
 Accuracy de validación: 83.15%
 Accuracy de prueba: 81.01%

Diferencias de accuracy

Diferencia Train-Validation: 11.80%
 Diferencia Train-Test: 13.94%

REPORTE DE CLASIFICACIÓN - VALIDACIÓN

	precision	recall	f1-score	support
0	0.85	0.88	0.87	112
1	0.79	0.74	0.77	66
accuracy			0.83	178
macro avg	0.82	0.81	0.82	178
weighted avg	0.83	0.83	0.83	178

REPORTE DE CLASIFICACIÓN - PRUEBA

	precision	recall	f1-score	support
0	0.82	0.87	0.84	105
1	0.79	0.73	0.76	74
accuracy			0.81	179
macro avg	0.81	0.80	0.80	179
weighted avg	0.81	0.81	0.81	179

Iteración 2 (mínimos de hoja)

Diagnóstico y explicación el grado de bias o sesgo

Considerando que el modelo ahora tiene un `max_depth` de 10, podemos ver que el `accuracy` tiende a disminuir conforme aumenta la cantidad de `min_samples_leaf` aumenta. Vale la pena señalar que el valor más alto de `accuracy` para los datos de prueba se encontraba consistentemente en `min_samples_leaf` = 2. Los valores de `accuracy` llegan a 82% - 83% superando en uno o dos puntos porcentuales al modelo original. En general esto indica un sesgo bajo.

Diagnóstico y explicación el grado de varianza

La varianza disminuye conforme aumenta la cantidad mínima de hojas por nodo. Al inicio estos valores son mucho más cercanos, pero eventualmente se separan principalmente por la disminución en el `accuracy` con los valores de test, mientras que los valores de validación mantienen un `accuracy` más estable.

Diagnóstico y explicación el nivel de ajuste del modelo

El `accuracy` elevado para los datos de entrenamiento y su disparidad con los datos de validación es indicativo de overfitting, a pesar de esto, esta versión del modelo muestra mejor desempeño en comparación con el modelo original.

Resultados

Gráficas para determinar el sesgo.







Tabla de los datos de accuracy para las gráficas anteriores.

```
=====
RESULTADOS DEL AJUSTE DE min_samples_leaf
=====
```

min_samples_leaf	accuracy_train	accuracy_validation	accuracy_test	diferencia_train_validation	diferencia_train_test
1	0.983146	0.803371	0.810056	0.179775	0.173090
2	0.908240	0.831461	0.826816	0.076779	0.081424
3	0.893258	0.831461	0.826816	0.061798	0.066443
4	0.880150	0.820225	0.810056	0.059925	0.070094
5	0.861423	0.848315	0.793296	0.013109	0.068127
6	0.853933	0.848315	0.793296	0.005618	0.060636
8	0.846442	0.853933	0.798883	-0.007491	0.047559
10	0.840824	0.842697	0.804469	-0.001873	0.036355

Gráficas para determinar la varianza



Iteración 3 (Búsqueda de valores con grid search)

Para esta iteración omitiré el análisis de cada sección dado que el grid search que realicé devolvió prácticamente el mismo árbol al que ya había llegado yo en las iteraciones anteriores. Incluyo los resultados de este árbol, pero llegado a este punto concluyo que para ver mejorías en el rendimiento del modelo es necesario modificar el dataset para acomodar al modelo.

Resultados

```
=====
MEJORES HIPERPARÁMETROS
=====
{'max_depth': 10, 'max_features': 'sqrt', 'min_samples_leaf': 3, 'min_samples_split': 6, 'n_estimators': 406}
=====
MEJOR ACCURACY DE VALIDACIÓN CRUZADA
=====
0.8166108270146358
=====
RESULTADOS DEL MEJOR RANDOM FOREST
=====
Accuracy entrenamiento: 0.8933
Accuracy validación:    0.8315
Accuracy prueba:        0.8324
Diferencia Train-Validation: 0.0618
Diferencia Train-Test: 0.0609
```

Iteración 4 (Modificación al dataset)

Identifiqué la importancia de las variables y eliminé aquellas con la menor importancia. Después de esto volví a correr la búsqueda con grid search y en general sí hubo un aumento general en rendimiento.

Se puede ver un fit, sigue habiendo mayor accuracy con datos de entrenamiento, pero solo con una diferencia del 8% y el accuracy con los datos de prueba llega hasta el 84%.

Resultados

```
=====
IMPORTANCIA DE LAS VARIABLES
=====
      variable  importancia
numericas__Fare    0.228490
categoricas__Sex_male  0.227338
categoricas__Sex_female  0.213174
numericas__Age      0.191510
numericas__Pclass   0.139488
```

```
=====
RESULTADOS DEL MEJOR RANDOM FOREST
=====
Accuracy entrenamiento: 0.8745
Accuracy validación:    0.8427
Accuracy prueba:        0.8156
Diferencia Train-Validation: 0.0318
Diferencia Train-Test: 0.0589
=====
RESULTADOS DEL AJUSTE DE min_samples_leaf
=====
min_samples_leaf  accuracy_train  accuracy_validation  accuracy_test  diferencia_train_validation  diferencia_train_test
1                0.983146        0.820225            0.815642        0.162921                    0.167504
2                0.925094        0.837079            0.837989        0.088015                    0.087105
3                0.895131        0.837079            0.832402        0.058052                    0.062729
4                0.880150        0.820225            0.832402        0.059925                    0.047748
5                0.857678        0.837079            0.804469        0.020599                    0.053209
6                0.850187        0.825843            0.804469        0.024345                    0.045718
8                0.840824        0.820225            0.798883        0.020599                    0.041941
10               0.838951        0.837079            0.804469        0.001873                    0.034482
```

Conclusión

Tuve que haber hecho consideraciones desde la elección inicial del modelo y el dataset para asegurarme de que estos fueran más compatibles, prestándose a un mayor grado de experimentación con los hiperparámetros.