

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Momento de Retroalimentación: Módulo 2 Implementación de una técnica de aprendizaje máquina sin el uso de un framework. (Portafolio Implementación)

Jorge Adolfo Ramírez Uresti

Israel González Huerta A01751433

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Miércoles 10 de septiembre de 2026

Implementación y limitaciones


Decidí implementar algoritmos para la construcción y prueba de un árbol de decisiones. En su implementación actual el árbol no tiene un límite de profundidad o tamaño mínimo para una hoja, esto hace que sea propenso a overfitting. El árbol solo funciona con datasets donde todas las columnas son categóricas y columna target (los valores a predecir) están en la última columna.

Resultados

Dentro de la carpeta de Data se pueden encontrar 3 datasets. Tree_data.csv son los mismos datos de la actividad 7 sobre tennis. dataset_compra_coche.csv fue generado por chatgpt y solo fue para realizar pruebas con más columnas (no recomiendo probarlo porque no sé si los datos de la IA sí tenían patrones intencionales y discernibles. car_data.csv fue obtenido de “Bohanec, M. (1988). Car Evaluation [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5JP48>.”, consiste de 1,728 registros y 6 atributos categóricos más la clase objetivo.

Estos son los resultados de correr el código con el dataset de car_data.csv 3 veces para mostrar una muestra de los resultados obtenidos. La discusión sobre qué significan ocurre en la siguiente sección, Análisis de resultados.

1.-




Accuracy: 0.882466281310212

Reporte de clasificación:

	precision	recall	f1-score	support
acc	0.87	0.78	0.82	111
good	0.81	0.59	0.68	29
unacc	0.90	0.96	0.93	358
vgood	0.71	0.48	0.57	21
accuracy			0.88	519
macro avg	0.82	0.70	0.75	519
weighted avg	0.88	0.88	0.88	519

2.-




Accuracy: 0.8921001926782274

Reporte de clasificación:

	precision	recall	f1-score	support
acc	0.90	0.78	0.83	120
good	0.80	0.35	0.48	23
unacc	0.89	0.98	0.93	354
vgood	0.84	0.73	0.78	22
accuracy			0.89	519
macro avg	0.86	0.71	0.76	519
weighted avg	0.89	0.89	0.88	519

3.-



Accuracy: 0.9017341040462428

Reporte de clasificación:

	precision	recall	f1-score	support
acc	0.91	0.75	0.82	119
good	0.69	0.64	0.67	14
unacc	0.91	0.98	0.94	363
vgood	0.88	0.65	0.75	23
accuracy			0.90	519
macro avg	0.85	0.76	0.79	519
weighted avg	0.90	0.90	0.90	519

Análisis de resultados

Las clases de acc y unacc presentan el mejor desempeño en prácticamente todas las métricas. Esto indica que el algoritmo identifica correctamente la gran mayoría de los vehículos que pertenecen a estas clases. En cambio, las clases good y vgood presentan un desempeño considerablemente menor, especialmente en recall. El promedio macro es inferior al accuracy, lo que indica que el modelo no identifica todas las clases con la misma efectividad.

El árbol de decisión obtuvo un buen desempeño general, alcanzando una accuracy de 86.32% sobre el conjunto de prueba. Sin embargo, este resultado debe interpretarse considerando el desbalance entre las clases, ya que unacc representa una proporción considerablemente mayor de los registros. Por esta razón, el buen desempeño del modelo sobre esta clase tiene un impacto importante en la accuracy general.

Al evaluar el árbol con los datos de entrenamiento se obtuvo una accuracy de 100.00%, mientras que con los datos de prueba se obtuvo una accuracy de 86.32%, dando una diferencia de 13.68 puntos porcentuales. Esta diferencia proporciona evidencia de overfitting, ya que el árbol logra clasificar perfectamente los datos que utilizó para aprender, pero su desempeño disminuye considerablemente al enfrentarse a datos que no utilizó durante el entrenamiento.

Los resultados de las tres ejecuciones también pueden variar debido a que los datos de entrenamiento y prueba se seleccionan aleatoriamente en una proporción de 70/30. Sin embargo, el comportamiento general del modelo se mantiene y presenta un mejor desempeño en las clases acc y unacc, mientras que good y vgood son las clases más difíciles de identificar.

Este comportamiento es consistente con las limitaciones actuales de la implementación. El árbol no establece un límite de profundidad ni un tamaño mínimo de hoja, por lo que continúa dividiendo los datos hasta alcanzar hojas puras o quedarse sin atributos disponibles. Esto permite que el árbol se adapte demasiado a los datos de entrenamiento y explica, al menos en parte, la diferencia observada entre el desempeño de entrenamiento y de prueba.

Una posible mejora sería implementar un límite de profundidad, un tamaño mínimo de hoja o algún mecanismo de poda. Estas modificaciones permitirían controlar el crecimiento del árbol y reducir el overfitting, mejorando potencialmente su capacidad para generalizar a datos que no utilizó durante el entrenamiento.

Replicar resultados / probar el modelo

Actualmente, cada vez que se corre el modelo elige aleatoriamente filas del dataset cargado en una proporción de 70 / 30. Bastaría con cargar el nuevo dataset a probar (siempre y cuando siga las restricciones menciona previamente) y cambiar la línea 30:

```
df = pd.read_csv("Data/car_data.csv")
```

para ver los resultados de otro dataset.